VectorDB Pro — 技术规格与使用手册

版本 3.2 | 发布日期：2024年9月15日 | 文档编号：VDB-SPEC-032

1. 产品概述

VectorDB Pro 是一款面向企业级 RAG（检索增强生成）场景设计的高性能向量数据库，由 NexusAI 公司于 2022 年首次发布。其核心能力包括：毫秒级 ANN（近似最近邻）检索、原生混合检索支持（向量 + BM25）、以及跨集群水平扩展。

当前最新稳定版本为 3.2，于 2024 年 9 月 15 日正式发布，取代了 2024 年 3 月发布的 3.1 版本。版本 2.x 系列已于 2024 年 6 月 30 日停止官方维护支持。

> **注意：**VectorDB Pro 与同类产品 VectorDB Lite 是完全独立的产品线。VectorDB Lite 面向个人开发者，最大支持 500 万向量，不支持集群部署，且不提供 SLA 保障。

2. 版本演进与关键变更

2.1 版本 3.2 新特性（当前版本）

版本 3.2 引入了以下重大更新：

- **稀疏-稠密混合索引：**同一 Collection 内可同时存储稠密向量（用于语义检索）与稀疏向量（用于关键词检索），无需维护两套存储。
- **动态 Schema：**支持在不停机的情况下向已有 Collection 新增字段，迁移成本降低约 70%。
- **多租户隔离增强：**引入 Partition Key 机制，同一物理集群内最多支持 10,000 个逻辑租户隔离。
- **压缩率提升：**新增 ZSTD 压缩支持，原始数据压缩率相比 3.1 版本的 LZ4 压缩提升约 35%。

2.2 版本 3.1 主要特性（已被取代）

版本 3.1 于 2024 年 3 月发布，主要新增了 GPU 加速索引构建能力（需 NVIDIA A100 或更高显卡），以及对 gRPC 流式接口的支持。该版本的默认压缩算法为 LZ4，最大 Collection 数量限制为 65,536 个。

> **已知问题：**版本 3.1 在并发写入超过 50,000 QPS 时存在内存泄漏（Issue #4821），该问题已在 3.2 版本中修复。

3. 性能基准指标

以下数据基于标准测试环境：32 核 CPU、256GB RAM、NVMe SSD，数据集规模 1 亿向量（768 维），测试工具为 ANN-Benchmarks v2.3。

指标	v3.2 (HNSW)	v3.2 (IVF-PQ)	v3.1 (HNSW)	说明
QPS（查询/秒）	142,000	98,000	127,000	单节点，top-10
P99 延迟	4.2 ms	6.8 ms	5.1 ms	不含网络开销
召回率 @10	99.1%	95.3%	98.8%	精确召回为基准
索引构建时间	18 分钟	9 分钟	22 分钟	1 亿向量，8 线程
内存占用	82 GB	31 GB	85 GB	含索引与原始向量

4. 系统容量限制

以下限制适用于 v3.2 版本的单集群部署。超出限制的需求请联系企业销售团队获取定制方案。

限制项	免费版	专业版	企业版
最大向量数量	100 万	5 亿	无限制（水平扩展）
最大 Collection 数	10	10,000	无限制
最大向量维度	2,048	32,768	32,768
单次批量写入	1,000 条	100,000 条	1,000,000 条
API 并发请求数	10	500	自定义
数据保留期限	7 天	180 天	永久

限制项	免费版	专业版	企业版
SLA 可用性保障	无	99.9%	99.99%

5. 支持的索引类型

VectorDB Pro v3.2 支持以下五种索引算法。**注意：ANNOY 索引在 v3.0 版本中已被废弃，v3.2 不再提供任何形式的 ANNOY 支持。**

HNSW（推荐）

分层可导航小世界图算法。最高召回率，查询延迟最低，但内存占用较高。适用于对精度要求高、内存资源充足的场景。构建时间随数据量线性增长。参数：M（图连接数，默认 16）、ef_construction（构建精度，默认 200）。

IVF-PQ

倒排文件索引 + 乘积量化。内存占用最低（约为 HNSW 的 38%），但召回率略低。适用于超大规模数据集（10 亿以上向量）或内存受限环境。参数：nlist（聚类中心数，默认 1024）、m（子空间数，默认 8）。

IVF-FLAT

倒排文件索引，无量化压缩。召回率接近精确检索（99.8% @10），但内存占用与原始数据相当。适合中等规模数据集（1,000 万向量以内）。

SCANN

Google 研究院提出的各向异性量化算法。在高维空间（1,024 维以上）中表现优于 IVF-PQ。v3.2 中为实验性功能（Beta），不建议用于生产环境。

DiskANN

微软研究院提出的基于 SSD 的索引算法。支持将索引存储在磁盘而非内存，适用于 RAM 严重不足的环境。查询延迟约为 HNSW 的 3-5 倍，但成本大幅降低。

6. 核心 API 参考

6.1 创建 Collection

创建向量集合时必须指定向量维度与距离度量类型。维度一旦设定后无法修改。

```
POST /v2/collections
{
  "name": "my_collection",
  "dimension": 1536,
  "metric_type": "COSINE",
  "index_type": "HNSW",
  "description": "OpenAI embeddings for article
search"
}
```

6.2 距离度量类型

支持三种距离度量：**COSINE**（余弦相似度，推荐用于文本向量）、**L2**（欧几里得距离，推荐用于图像向量）、**IP**（内积，仅适用于已归一化的向量）。不同度量类型之间的性能差异在实测中不超过3%。

6.3 身份验证

所有 API 请求必须携带 Bearer Token。API Key 在控制台生成，默认有效期为 90 天（企业版可配置为永不过期）。免费版不支持 IP 白名单功能；专业版及以上支持配置最多 50 个白名单 IP。

7. 已知限制与明确禁止的操作

以下操作在 VectorDB Pro v3.2 中**不被支持或明确禁止**：

- **不支持事务操作：**VectorDB Pro 不提供 ACID 事务保障，批量写入为最终一致性模型。
- **不支持向量维度修改：**Collection 创建后，维度字段不可更改，需删除重建。
- **不支持跨 Collection 联合查询：**单次查询只能在一个 Collection 内进行。
- **禁止直接访问底层存储：**不允许绕过 API 直接读写 RocksDB 存储层，违反此规定将导致数据损坏。
- **免费版不提供数据导出：**免费版用户无法使用数据导出（Export）API，需升级至专业版。

8. 常见问题与故障排查

Q: 查询召回率突然下降，如何排查？

首先检查索引是否需要重建（当增量写入量超过集合总量的 30% 时，HNSW 索引性能会显著退化）。其次检查 ef_search 参数是否被意外降低（默认值为 64，建议生产环境设置为 128）。

Q: 写入速度突然降低到预期的 20% 以下，可能的原因是什么？

最常见原因是触发了自动合并（Compaction）任务。当 Segment 数量超过阈值（默认 512 个）时，系统会自动触发后台合并，该过程会占用约 60-80% 的 I/O 资源。可通过 `GET /v2/system/compaction` 接口查看当前合并状态。

Q: 使用 IVF-PQ 索引时，如何在召回率和延迟之间取得最佳平衡？

增大 nprobe 参数（查询时探测的聚类中心数）可提升召回率但增加延迟。经验公式：nprobe = sqrt(nlist)，即当 nlist=1024 时，nprobe 设置为 32 可获得约 95% 的召回率。若需 99% 召回率，nprobe 需增大至 nlist 的 10% 以上。

本文档版权归 NexusAI 公司所有。文档中所有产品名称、版本号及性能数据均为测试用虚构内容，仅用于 RAG 系统评估目的。