RAG 测试问题集 — VectorDB Pro 技术规格文档

对应文档：rag_test_document.pdf（VectorDB Pro 技术规格 v3.2） | 共 10 题 | 涵盖 8 种测试维度

题型说明

标签	测试目标	对应 RAG 失败模式
factual	单跳事实检索	Embedding 未命中 / Chunk 切割断句
numerical	精确数值提取	数值上下文被 chunk 边界截断
multi-hop	跨 chunk 多步推理	top-k 截断导致部分证据丢失
negation	否定语义理解	LLM 忽略否定词，生成相反结论
unanswerable	无答案识别	LLM 幻觉生成，过度脑补
conflict	文档内矛盾识别	无冲突检测机制，随机采信一方
table	表格数值推理	表格行列关系在 chunk 后丢失
cross-section	跨章节综合推理	单个 chunk 不完整，需多段拼接

题目列表

Q1 factual

VectorDB Pro 当前最新稳定版本是什么？该版本是何时发布的？

标准答案

当前最新稳定版本为 3.2，于 2024 年 9 月 15 日正式发布。

来源章节： 第 1 节「产品概述」

> **预期失败模式：** 若 chunk 边界将版本号与日期切成两段，Embedding 可能只召回其中一段，导致答案不完整。

Q2 factual negation

VectorDB Pro v3.2 是否仍然支持 ANNOY 索引？

标准答案

不支持。ANNOY 索引在 v3.0 版本中已被废弃，v3.2 不再提供任何形式的 ANNOY 支持。

来源章节： 第 5 节「支持的索引类型」开头说明

> **预期失败模式：** 否定题。LLM 容易被「VectorDB 支持多种索引」的上下文误导，忽略明确的废弃声明，错误回答「支持」。

Q3 numerical table

在 1 亿向量规模下，v3.2 HNSW 索引的 P99 查询延迟是多少毫秒？与 v3.1 HNSW 相比提升了多少？

标准答案

v3.2 HNSW 的 P99 延迟为 4.2 ms，v3.1 HNSW 为 5.1 ms，v3.2 提升了约 17.6%（减少 0.9 ms）。

来源章节： 第 3 节「性能基准指标」表格

> **预期失败模式：** 需要同时提取同一行内两个不同列的数值并计算差值。表格若被展平为纯文本，行列对应关系极易丢失。

Q4 table numerical

专业版用户单次批量写入的上限是多少条？企业版的上限又是多少？

标准答案

专业版单次批量写入上限为 100,000 条，企业版上限为 1,000,000 条。

来源章节： 第 4 节「系统容量限制」表格

> **预期失败模式：** 需跨表格两列提取数据。若 chunk 只包含表格部分列，则答案不完整。

Q5 multi-hop cross-section

v3.1 版本存在一个内存泄漏问题，它在什么并发条件下触发？该问题在哪个版本中被修复？

标准答案

该内存泄漏（Issue #4821）在并发写入超过 50,000 QPS 时触发，已在 v3.2 版本中修复。

来源章节： 第 2.2 节「版本 3.1 主要特性」

> **预期失败模式：** 问题涉及两个独立信息点（触发条件 + 修复版本），若 chunk 粒度过细两条信息可能分属不同 chunk，导致多跳推理断链。

Q6 negation unanswerable

免费版用户可以使用数据导出（Export）API 吗？如果不能，需要升级到哪个版本？

标准答案

免费版用户不可以使用数据导出 API，需要升级至专业版（或更高）才能使用该功能。

来源章节： 第 7 节「已知限制与明确禁止的操作」

> **预期失败模式：** 双重测试：否定语义（「不可以」）+ 推断（需将「专业版」与「免费版不可用」两条信息组合）。LLM 可能混淆免费版与专业版的功能边界。

Q7 factual negation

VectorDB Pro 与 VectorDB Lite 有什么区别？VectorDB Lite 支持集群部署吗？

标准答案

两者是完全独立的产品线。VectorDB Lite 面向个人开发者，最大支持 500 万向量，不支持集群部署，且不提供 SLA 保障。

来源章节： 第 1 节「产品概述」注意事项

> **预期失败模式：** 信息位于正文注释段落，Embedding 相似度可能优先召回主体段落而非注释，导致 Lite 的限制信息丢失。

Q8 cross-section multi-hop

如果我想在 v3.2 中实现最低内存占用的向量检索方案，应该选择哪种索引？它的内存占用大约是多少 GB？

标准答案

应选择 IVF-PQ 索引，在 1 亿向量规模下内存占用约为 31 GB（约为 HNSW 82 GB 的 38%）。

来源章节： 第 3 节「性能基准指标」表格 + 第 5 节 IVF-PQ 描述

> **预期失败模式：** 需跨两个章节推理（性能表格确认数值 + 索引描述确认特性），典型的跨 chunk 多跳场景。

Q9 unanswerable

VectorDB Pro v3.2 的月度订阅价格是多少？

标准答案

文档中未提及任何价格或定价信息，该问题无法根据文档内容回答。

来源章节： 全文均无价格相关信息

> **预期失败模式：** 无答案识别测试。高质量 RAG 应明确返回「文档中未包含该信息」，而非幻觉生成一个价格数字。LLM 极易根据训练数据中的 SaaS 定价模式进行编造。

Q10 conflict cross-section

v3.2 版本的最大 Collection 数量是多少？（请注意文档中可能存在的不一致信息）

标准答案

文档中存在数据冲突：第 2.2 节描述 v3.1 限制为 65,536 个；第 4 节容量表格中专业版为 10,000 个，企业版为「无限制」。两处数据描述对象不同（v3.1 全局 vs v3.2 分版本），不可一概而论，需结合版本与套餐作区分回答。

来源章节： 第 2.2 节「版本 3.1 特性」+ 第 4 节「系统容量限制」表格

> **预期失败模式：** 冲突检测测试。65,536 与 10,000 实际描述不同对象，但表述方式容易让 RAG 混淆。理想 RAG 应识别冲突并区分语境，而非随机采信一方。

本问题集专为 RAG 系统评估设计，涵盖 factual、numerical、multi-hop、negation、unanswerable、conflict、table、cross-section 共 8 种测试维度。建议配合 RAGAS 框架进行自动化评分。